

스마트폰 센서 데이터를 활용한 인간 활동 분류(HAR) 및 머신러닝 모델 비교 분석

데이터마이닝(C)

담당 교수님: 신성 교수님

11조 2271036 윤준영 2191096 김용우 2271252 유민혁

제출일: 2026.06.24

1. 프로젝트 개요 및 문제 정의 (Problem Definition)

1.1. 연구 배경 및 필요성

현대 스마트폰, 웨어러블 기기, 자율주행, 드론 등에서는 움직임과 방향을 감지하는 핵심 모션 센서인 가속도계(Accelerometer), 자이로스코프(Gyroscope) 등의 고성능 센서가 기본적으로 내장되어 있다. 이러한 센서 데이터를 활용한 인간 활동 분류(Human Activity Recognition, HAR) 기술은 별도의 고가 장비를 부착하지 않고도 사용자의 위치나 자세 정보 등을 실시간으로 파악할 수 있다는 점에서 일상적인 사물에 컴퓨터 칩과 센서가 내장되어 네트워크로 연결되는 유비쿼터스(Ubiquitous) 컴퓨팅의 핵심 연구 분야로 주목받고 있다. 특히, 고령화 사회에서 노약자의 낙상 감지 시스템, 스마트 헬스케어의 소모 칼로리 자동 추적, 사용자의 행동 패턴을 기반으로 한 2차 보안 인증 등 다양한 도메인에서 그 필요성이 증대되고 있다.

1.2. 프로젝트 수행 목표

본 프로젝트는 스마트폰 센서로부터 수집된 561차원의 고차원 데이터 속에서, 데이터마이닝 기법을 활용하여 인간이 직관적으로 인지하기 어려운 미세한 파형의 패턴을 추출하는 것을 목적으로 한다. 수업 시간에 학습한 비지도학습(K-Means 군집화) 기법과 지도학습(KNN 분류 및 앙상블) 기법을 유기적으로 연계 적용함으로써, 모델의 분류 매커니즘을 심층적으로 이해하고 성능등을 비교 분석해보며 데이터 특성에 맞는 최적의 파이프라인을 구축하고자 한다.

2. 데이터 수집 및 데이터셋 설명 (Data Collection & EDA)

2.1. 데이터셋 출처 및 명세

본 프로젝트에서는 공인된 벤치마크 데이터인 **UCI Machine Learning Repository**의 **HAR** 데이터셋을 활용하였다. 이 데이터들은 19세에서 48세 연령대 총 30명의 실험자가 스마트폰을 허리에 착용하고 일상적인 6가지 활동을 수행할 때 기록된 데이터이다.

데이터셋의 총 규모: 전체 10,299개의 샘플 데이터와 562개의 변수(독립 변수 561개 + 종속 변수 1개)로 구성되어 있다.

독립 변수(Feature): 스마트폰 내부의 가속도계(Accelerometer)로부터 측정된 3축 선형 가속도와 자이로스코프(Gyroscope)로부터 측정된 3축 각속도 신호를 총 561개의 정교한 핵심 특징 변수로 정형화되어 제공된다.

종속 변수(Target): 사용자의 상태를 나타내는 6가지의 활동 범주로 이루어져 있으며, 동적 활동 3종과 정적 활동 3종으로 분류된다.

정적 활동(Static):

Sitting(앉기), Standing(서기), Laying(눕기)

동적 활동 (Dynamic):


Walking(걷기), Walking Upstairs(계단 오르기), Walking Downstairs(계단 내려가기)

데이터셋 출처: [Human Activity Recognition Using Smartphones - UCI Machine Learning Repository](https://archive.ics.uci.edu/ml/dataset/human+activity+recognition+using+smartphones)

2.2. 탐색적 데이터 분석

데이터셋 내 편향으로 인한 모델의 오작동을 방지하기 위해 각 활동별 데이터 분포를 확인하였다.

다음 <그림 1>은 활동 라벨별 데이터 분포 수치를 보여주는 막대그래프이다.



<그림 1>

전체 데이터(샘플) 개수: 10299개
전체 변수(특징 + 라벨) 개수: 562개

활동 라벨별 데이터 분포

- Walking (라벨 1): 1722개
- Walking Upstairs (라벨 2): 1544개
- Walking Downstairs (라벨 3): 1406개
- Sitting (라벨 4): 1777개
- Standing (라벨 5): 1906개
- Laying (라벨 6): 1944개

6개의 활동 데이터가 약 1,400개~1,900개 사이로 비교적 균일한 비율을 유지하고 있음을 확인하였다. 이는 데이터마이닝 모델 학습 시 특정 데이터에 과도하게 편향되지 않는 안정적인 데이터 분포를 가졌음을 증명한다.

3. 데이터 전처리 및 차원 축소 (Preprocessing & PCA)

3.1. 데이터 결측치 및 이상치 처리

본 프로젝트에서는 결측치가 발생할 경우에 대비하여, 열별 평균값(`X.mean()`)으로 대체하는 전처리 로직을 코드 상에서 설계하였지만, 본 벤치마크 데이터셋은 사전 가공이 잘 정돈된 데이터이므로 전체 561개의 영역에서 단 하나의 결측치도 발견되지 않았다.

데이터셋 내 결측치 개수: 0개

신호 튜브 현상이나 노이즈로 인한 이상치 또한 데이터 수집 단계에서 2.56초의 고정 폭 슬라이딩 윈도우와 버터워스 저역 통과 필터를 사용하여 물리적으로 전처리 되었음을 파악하였고([Human Activity Recognition Using Smartphones - UCI Machine Learning Repository](#) 데이터 정보 참고) 이에 따라 본 프로젝트에서는 데이터의 분포를 유지하는 방향으로 진행하였다.


3.2 데이터 정규화 및 표준화

본 프로젝트의 핵심 독립 변수인 가속도계 데이터와 자이로스코프 데이터는 서로 완전히 다른 물리적 단위와 수치를 가진다. 이 상태 그대로 유클리드 거리 기반 알고리즘(K-Means, K-NN)을 적용하게 되면, 절댓값의 스케일이 상대적으로 큰 변수가 거리 계산 과정을 지배하여 모델의 분류 경계를 심각하게 왜곡시키는 문제가 발생하므로 이러한 문제를 방지하고 모든 변수가 모델 학습에 동등하게 기여할 수 있도록, 특징 행렬 전체에 **StandardScaler**를 적용하였다. 각 변수의 평균을 0, 표준편차를 1로 변환하는 표준 정규화(Standardization)를 수행함으로써 거리 왜곡의 원인을 기술적으로 방지하였다.

✔ StandardScaler 표준화 완료!

3.3 주성분 분석(PCA)을 통한 차원 축소

561개의 방대한 특징 변수는 정보량이 많다는 장점이 있으나 서로 비슷한 성격의 변수가 엄청나게 많고 데이터 공간이 너무 방대하기 때문에 분석 알고리즘 모델이 연산해야 될 양이 너무 많아 컴퓨터가 무거워지고 중요하지 않은 자잘한 변수들까지 모델이 학습하여 과적합(Overfitting)이 발생할 확률이 높아진다. 예를 들어 'X축 가속도 평균'과 'X축 가속도 중앙값'은 서로 강한 상관관계를 가질 확률이 높다. 이러한 현상은 회귀나 거리 기반 알고리즘의 안정성을 해칠 수 있기 때문에 본 프로젝트에서는 모델의 학습 속도를 높이고 데이터의 핵심 구조를 시각적으로 파악하기 위해 고차원 특징 공간을 선형적으로 압축하는 주성분 분석(PCA)을 수행하였다. 다음 <그림2>는 561차원의 데이터를 단 2개의 주성분으로 압축하여 나타낸 산점도 그래프이다.



<그림 2>

본 프로젝트의 561차원의 데이터를 단 2개의 주성분(PC1, PC2)으로 압축했을 때 전체 데이터셋이 가지고 있던 총 분산(정보량)의 **56.98%**을 보존할 수 있음을 확인하였다.

✓ PC1 분산 설명력: 50.74%

✓ PC2 분산 설명력: 6.24%

👉 단 2개의 주성분으로 전체 데이터가 가진 정보의 56.98%를 보존했습니다.

이 수치는 다소 완만한 수치이긴 하나 고차원 센서 데이터 고유의 복잡성과 미세 노이즈 분산이 넓게 퍼져 있기 때문이며, 사후 지도학습(K-NN, Random Forest) 모델 적용 결과 **90%**를 상회하는 최종 분류 정확도를 기록한 것을 미루어 볼 때, 본 PCA 연산이 전체 분산 수치와 상관없이 데이터 정보를 잘 추출 했음을 시사한다.

3.4 시각화 그래프를 통한 인사이트 도출

위의 <그림 2>의 2차원 산점도를 분석한 결과, 정답 정보를 전혀 주지 않았음에 데이터 분포 자체에 명확한 기하학적 패턴이 존재함이 입증되었다. 1, 2, 3번(Walking 계열)의 동적 활동 데이터는 공간의 좌측 영역에 뭉쳐 있고, 4, 5, 6번(Sitting, Standing, Laying)의 정적 활동 데이터는 우측 영역에 거대한 군집을 이루고 있다. 이는 인간의 움직임 유무에 따른 신호의 변동성이 전체 변수 중 가장 강력한 변수(PC1 축) 역할을 한다는 것을 나타낸다. 또한, 앉기(Sitting, 4번)와 서 있기(Standing, 5번) 데이터는 공간 상에서 격렬하게 중첩되어 있음을 발견하였다. 두 활동 모두 스마트폰이 정지해 있어 중력 가속도 및 각속도의 파형 데이터가 거의 유사하기 때문이라고 추측하였고 이러한 데이터 특성을 고려했을 때 더

정교한 지도학습 모델이 추가로 필요할 것으로 예측 되었고 도출 해낸 인사이트를 토대로 모델 설계의 전략을 구상했다.

4. 모델 설계 및 적용 (Model Implementation)

4.1. K-Means 군집화 (비지도학습)


4.1.1 관련 이론 및 기술

K-Means 알고리즘은 비지도학습(Unsupervised Learning)의 가장 대표적인 분할 기반 군집화 알고리즘이다. 사전에 정의된 군집의 수 **K**에 따라, 데이터 공간 상에서 거리가 가까운 데이터들을 하나의 그룹으로 묶는 것을 목적으로 한다. 알고리즘의 수학적 목적 함수는 각 군집의 중심점(Centroid)과 해당 군집에 속한 데이터들 간의 거리의 제곱합인 **Inertia**(군집 내 오차 제곱합)을 최소화하는 것이다. 알고리즘의 연산 프로세스는 다음의 4단계 반복 과정을 거친다.

- 1. 초기화 :** 데이터 공간 상에 임의의 **K**개의 중심점을 배치한다. (본 프로젝트에서는 초기 중심점의 무작위 선택 문제를 보완하고 전역 최적해에 수렴하도록 **n_init=10** 및 **k-means++** 기법을 적용하였다.)
- 2. 군집 할당 :** 모든 데이터 샘플에 대해 가장 가까운(유클리드 거리 기반) 중심점을 계산하여 해당 군집으로 할당한다.
- 3. 중심점 업데이트 :** 각 군집에 할당된 데이터들의 평균(Mean) 위치를 계산하여 새로운 군집 중심점으로 이동시킨다.
- 4. 반복 및 수렴 :** 중심점의 위치 변화가 없거나 지정된 최대 반복 횟수에 도달할 때까지 2단계와 3단계를 반복 수행한다.

4.1.2 K-Means 설계 및 하이퍼파라미터(K) 결정

비지도학습은 지도학습과 달리 정답 라벨(Label)이 주어지지 않으므로, 데이터 자체의 기하학적 구조만으로 최적의 군집 수 **K**를 결정해야 하는 타당성 검증이 필수적이다. 따라서 본 프로젝트에서는 모델 설계의 객관성을 확보하기 위해 군집 수 **K**를 1부터 7까지 순차적으로 증가시키며 모델을 반복 학습시키는 **Elbow Method**(엘보우 기법) 검증을 설계하였다. 여기서 **Elbow Method**(엘보우 기법)을 간략하게 설명하자면 “데이터를 몇 개의 그룹으로 나누는 것이 가장 형평성 있고 수학적으로 올바른가?”를 결정하는 하이퍼파라미터 튜닝 기법으로 **K**를 늘려나가면서 군집 내 오차 제곱합(Inertia) 가장 효율적으로 줄어드는 부분을 최적의 **K**로 정하는 기법이다. **K** 값이 너무 작다면 오차(Inertia)가 커지고 너무 커진다면 과적합(Overfitting)이 발생한다. 다음의 <그림 3>은 **K**에 따른 오차를 계산한 **Elbow Method** 그래프이다.




<그림 3>

<그림 3>의 결과 도출된 엘보우 그래프를 분석하면, $K=2$ 인 지점에서 Inertia 수치의 감소 기울기가 가장 급격하게 꺾이며 완만해지는 명확한 '팔꿈치(Elbow)' 형태의 변곡점이 관찰된다. 이는 거리 공간 상에서 데이터를 2개의 군집으로 분할할 때 오차 감소의 효율성이 가장 극대화됨을 수학적으로 증명하는 근거이다. 이에 따라 최종 군집 수 $K=2$ 로 확정하여 모델링을 진행하였다.


4.1.3 K-Means 군집화 수행 결과 및 교차 분석

최적의 파라미터($K=2$)로 학습된 K-Means 모델의 군집화 성능을 확인하기 위해, 앞서 전처리 단계에서 추출한 PCA 공간 상에 군집 라벨별 산점도를 투영하였다. 다음의 <그림4>는 파라미터($K=2$)로 군집화 하여 나타낸 산점도이다.



<그림 4>

또한, 실제 활동 레이블과의 일치 여부를 검증하고자 교차 분석표(Cross Tabulation)를 도출하였다.



<그림 5>


이러한 교차 분석 결과를 확인해본 결과 라벨 정보를 전혀 제공하지 않은 채 기하학적 거리만으로 학습했음에도 불구하고 매우 정교한 패턴 분리가 일어났다. 실제 라벨 1, 2, 3번에 해당하는 동적 활동(Walking 계열) 데이터는 대부분 Cluster 0으로 묶였으며, 4, 5,

6번에 해당하는 정적 활동(**Sitting, Standing, Laying**) 데이터는 압도적인 비율로 Cluster 1에 할당되었다.

4.1.4 K-Means 분석 결과에 대한 인사이트 및 한계

위 <그림 5>은 최적의 파라미터를 통해 동적 활동(Walking 계열) 데이터와 정적 활동(Sitting, Standing, Laying) 데이터를 완벽에 가깝게 분리할 수 있다는 걸 보여준다. 이는 인간의 움직임 유무에 따라 발생하는 가속도 및 각속도 센서의 수치가 데이터를 구분 짓는 강력한 특징임을 입증 할 수 있다. 그러나 K-Means 모델링을 통해 비지도학습 알고리즘의 명확한 한계를 파악하였다. K-Means는 데이터 간의 공간적 거리에만 의존하여 구형(Spherical) 모양으로 군집을 형성하는 특성이 있다. 이로 인해 전체적인 '동적/정적'의 두 도메인은 훌륭히 격리 했으나, 실제 활동 범주인 6개 구역을 온전히 찾아내기 위해 K=6으로 확장할 경우 <그림 6>과 같은 결과를 보여준다.

K-Means Clustering Result (K=6) - Limitations of Unsupervised Learning



```

=== 🎨 [K=6] 실제 활동 라벨과 군집화 결과 비교 (Cross Tabulation) ===
Cluster Label (0-5)    0    1    2    3    4    5
Actual Activity
Laying                  54    0    0    5  329 1556
Sitting                1238    0    0    1  447  91
Standing              1346    0    0    0  560    0
Walking                 0   84  741  897    0    0
Walking Downstairs     0  214  882  310    0    0
Walking Upstairs       0    9  297 1236    2    0
  
```

<그림 6>

실제 활동 수와 동일하게 K=6으로 K-Means 군집화를 수행한 결과 실제 라벨당 하나씩 클러스터가 나누어 진것이 아니라 데이터들이 뒤죽박죽 섞여있는 결과를 볼 수 있다. 동적

활동(Walking, Walking Upstairs, Walking Downstairs)은 3개의 명확한 활동 경계로 쪼개지는 대신, 거리 상 가깝다는 이유로 하나의 클러스터에 두 활동이 무분별하게 뭉치거나 한 활동이 두 개의 클러스터로 과하게 쪼개지는 흐름을 보였다. 또한, PCA 분석을 통해 미리 확인했듯이 알고리즘이 '앉기'와 '서 있기'라는 정적인 특성을 구분하여 클러스터를 나누는 것이 아니라, 두 활동의 데이터가 여러 클러스터에 아무런 규칙 없이 뒤죽박죽 섞여서 파편화된 것을 볼 수 있다. K-Means는 정답(라벨)을 모른 채 단순 유클리드 공간적 거리가 가까우면 무조건 그룹을 자르기 때문에, 측정값이 거의 동일하여 공간 상에 완벽히 겹쳐 있는 두 활동을 스스로 분리하지 못하고 무의미하게 과적합(Overfitting)되어 버리는 치명적인 한계를 증명한다.

결과적으로 K-Means 군집화는 센서 데이터의 대략적인 흐름을 파악하는 데는 유용하지만 수치 변화가 거의 유사한 상태의 미세 경계를 정밀 분류하는 데는 한계가 있음이 확인되었다. 본 프로젝트에서 이러한 비지도학습의 한계를 극복하기 위해, 다음 단계에서 정답 라벨 정보를 명시적으로 학습하여 데이터들을 정교하게 튜닝할 수 있는 지도학습 기반의 K-NN 분류 및 Random Forest 앙상블 모델을 도입하려한다.

4.2. K-NN 분류 (지도학습)

4.2.1 관련 이론 및 기술

1) K-최근접 이웃 (K-NN) 분류 알고리즘

본 프로젝트에서는 스마트폰 센서 데이터를 바탕으로 사용자의 6가지 세부 행동을 분류하기 위해 대표적인 지도 학습 알고리즘인 K-NN을 활용하였다. K-NN 알고리즘은 새로운 데이터가 입력되었을 때, 기존의 훈련 데이터 공간에서 거리가 가장 가까운 K개의 이웃 데이터를 찾아내는 거리 기반 알고리즘이다. 찾아낸 K개의 이웃들이 가진 라벨(정답) 중에서 가장 많이 등장한 클래스를 다수결의 원칙에 따라 새로운 데이터의 최종 라벨로 예측하는 직관적인 원리로 작동한다.

2) 하이퍼파라미터 튜닝

머신러닝 모델에는 학습 데이터를 통해 기계가 스스로 찾아내는 파라미터와, 분석가가 사전에 직접 설정해주어야 하는 하이퍼파라미터가 존재한다. 하이퍼파라미터 튜닝은 모델의 성능을 극대화하고 일반화 능력을 높이기 위해 이 설정값들의 최적의 조합을 찾아내는 실험 과정이다. K-NN 알고리즘의 경우, 탐색할 이웃의 수인 K가 대표적인 하이퍼파라미터이다. K값을 적절히 조절하지 않으면 데이터의 노이즈까지 학습하는 과적합이나, 데이터의 패턴을 충분히 반영하지 못하는 과소적합이 발생할 수 있으므로 튜닝 과정이 필수적으로 요구된다.

3) 혼동 행렬 (Confusion Matrix)

혼동 행렬은 분류 모델의 성능을 평가할 때, 단순히 전체 데이터 중 정답을 맞힌 비율인 정확도만 확인하는 것을 넘어 모델이 어떤 클래스를 정확히 맞히고, 어떤 클래스를 서로 헷갈려 하는지를 구체적으로 파악하기 위해 사용하는 평가 지표이다. 실제 정답과 모델의 예측값을 교차표 형태로 나타내어, 정답을 맞힌 건수와 오답을 낸 건수를 세밀하게 시각화한다. 이를 통해 본 프로젝트와 같은 다중 클래스 분류 문제에서 모델의 특정 행동

분류에 대한 취약점을 파악하고, 정밀도, 재현율, F1-점수 등의 심화 평가 지표를 산출하는 핵심적인 바탕이 된다.

4.2.2 모델 설계 및 실험 방법

1) 학습 및 평가 데이터 분할

전처리 과정을 거친 스마트폰 센서 데이터(**X_scaled**)와 활동 라벨(**y**)을 모델 학습용과 최종 평가용으로 분할하였다. 본 프로젝트에서는 모델이 센서 패턴을 충분히 학습할 수 있도록 전체 데이터의 **70%**를 훈련용으로 배정하고, 모델의 일반화 성능을 객관적으로 검증하기 위해 나머지 **30%**를 평가용으로 분리하였다. 또한, 데이터 분할 시 무작위 추출로 인해 실험할 때마다 결과가 변동되는 것을 방지하고 실험의 재현성을 확보하기 위해, 파이썬 코드 내에서 난수 발생 초기값(**random_state**)을 고정하여 통제된 실험 환경을 설계하였다.

2) 하이퍼파라미터 튜닝

K-NN 알고리즘의 분류 성능을 결정짓는 핵심 하이퍼파라미터인 이웃의 수(**K**)를 최적화하기 위해 파이썬의 반복문(**for**)을 활용한 하이퍼파라미터 튜닝을 설계하였다. **K**값을 특정 숫자로 임의 지정하지 않고, **2**부터 **21**까지 순차적으로 대입하며 모델의 예측 정확도 변화를 체계적으로 관찰하는 실험 방식을 채택하였다.

[모델 학습 및 튜닝 절차]


1. **K**값을 **2**부터 **21**까지 **1**씩 증가시키며 **K-NN** 분류기 모델을 생성한다.
2. 분리해 둔 **70%**의 훈련 데이터를 입력하여 각 모델을 학습시킨다.
3. 학습된 모델에 **30%**의 평가 데이터를 입력하여 분류 정확도를 측정하고 기록한다.
4. 측정된 정확도 변화 추이를 꺾은선 그래프로 시각화하여 비교 분석하고, 정확도가 최고점에 도달하는 **K**값을 해당 모델의 최적 하이퍼파라미터로 선정한다.

이러한 체계적인 반복 튜닝 과정을 통해 모델의 성능을 극대화할 수 있는 가장 견고한 **K**값을 도출하였으며, 이렇게 검증된 세팅을 바탕으로 최종 모델을 구축하여 분류 성능 지표를 산출하였다.

4.2.3 K-NN 알고리즘 수행 결과 및 분석

1) 수행 결과 요약 및 최종 결과

파이썬 반복문을 활용한 하이퍼 파라미터 튜닝 결과, 분류 정확도가 최고점에 도달하는 최적의 이웃 수(**K**)는 <그림 7>에서 볼 수 있듯이 **7**로 도출되었다.



<그림7>

<그림8>은 도출된 최적의 하이퍼 파라미터($K=7$)를 적용하여 최종 K-NN 모델을 학습시킨 후, 전체 데이터의 30%인 평가 데이터를 통해 성능을 검증한 결과이며 전체 분류 정확도 96%라는 우수한 최종 결과를 달성하였다.

```

=== 🌈 K-NN 최종 분류 결과 (Classification Report) ===

```


	precision	recall	f1-score	support
Walking	0.98	1.00	0.99	539
Walking Upstairs	0.98	0.99	0.98	424
Walking Downstairs	1.00	0.96	0.98	420
Sitting	0.93	0.88	0.90	563
Standing	0.89	0.93	0.91	547
Laying	0.99	1.00	1.00	597
accuracy			0.96	3090
macro avg	0.96	0.96	0.96	3090
weighted avg	0.96	0.96	0.96	3090

<그림8>

앞선 비지도 학습(K-Means) 단계에서는 라벨 없이 센서 데이터만을 이용하여 사용자의 활동을 정적 활동과 동적 활동이라는 2개의 큰 군집으로 묶는 데 그쳤으나, 실제 정답데이터를 활용한 지도 학습(K-NN)을 적용함으로써 6가지의 세부적인 일상 행동을 기계가 스스로 명확하게 구분해 내는 고도화된 성과를 거두었다.

2) 주요 분석 결과 및 확인 사항

단순한 정확도 수치에 의존하지 않고 모델의 구체적인 예측 패턴과 취약점을 분석하기 위해 혼동 행렬과 분류 보고서를 활용하여 결과를 심층 분석하였으며, 주요 확인 사항은 다음과 같다.



<그림 9>

1. 동적 활동 및 눕기 상태의 완벽한 분류

혼동 행렬 분석 결과, '걷기(Walking)', '계단 오르기(Walking Upstairs)', '계단 내리기(Walking Downstairs)'와 같은 동적 활동과 '눕기(Laying)' 상태에서는 모델이 거의 완벽한 분류 성능을 보여주었다. 이는 걷거나 계단을 오르내리는 행동의 경우 스마트폰의 가속도 및 자이로스코프 센서의 변화 폭과 주기적 패턴이 뚜렷하게 나타나고, 눕기 상태 역시 서 있을 때와 스마트폰이 받는 중력의 방향이 확연히 달라져 K-NN 알고리즘이 데이터 간의 거리를 쉽게 구분할 수 있었기 때문으로 분석된다.

2. 정적 활동(앉기 vs 서기) 분류의 혼동 발생

전체적으로 높은 성능에도 불구하고, 혼동 행렬의 오답 패턴을 확인한 결과 모델이 유독 '앉기(Sitting)'와 '서기(Standing)' 활동을 명확히 구분하는 데 어려움을 겪는 것을 확인하였다. 실제 '앉기' 데이터 563개 중 63개를 '서기'로 잘못 예측하였으며, 반대로 실제 '서기' 데이터 547개 중 37개를 '앉기'로 잘못 예측하는 상호 혼동 현상이 두드러지게 발생하였다.

4.2.4 K-NN 알고리즘의 한계점 및 향후 개선 방향

앉기와 서기 활동에서 오분류가 빈번하게 발생한 원인은, 두 활동 모두 움직임이 거의 없는 정적인 상태이며 주머니에 위치한 스마트폰 센서가 측정하는 가속도 및 중력 방향 패턴이 데이터 공간상에서 매우 가깝게 분포하기 때문이다. 단순히 데이터 간의 거리만을 기반으로 다수결 판정을 내리는 K-NN 알고리즘의 특성상, 이처럼 두 클래스의 특성이 미세하게 겹치는 경계면에서는 분류 성능에 한계가 드러남을 확인하였다.

이러한 K-NN의 오분류 한계를 극복하기 위해서는 데이터의 거리에만 의존하지 않고, 변수별 중요도를 파악하여 여러 가지 질문을 통해 데이터를 세밀하게 분할하는 트리 기반 알고리즘이 필요하다. 따라서 향후 개선 방향으로 다수의 의사결정트리를 생성하고 이들의 예측을 종합하는 앙상블(Ensemble) 기법인 Random Forest 모델을 추가로 도입하고자 한다. 이를 통해 앞기와 서기를 구분 짓는 미세한 센서 패턴의 차이를 잡아내어 분류 정확도를 96% 이상으로 끌어올리고, 가장 성능이 우수한 최종 모델을 선정하고자 한다.

4.3. Random Forest (앙상블 학습)

4.3.1 관련 이론 및 기술

1) 랜덤 포레스트 (Random Forest) 앙상블 알고리즘

본 과정에서는 앞선 거리 기반 알고리즘(K-NN)의 오분류 한계를 극복하고 분류 성능을 끌어올리기

위해 대표적인 의사결정트리 알고리즘인 랜덤 포레스트를 활용하였다.

단독 의사결정트리 알고리즘은 전체 데이터와 변수를 통해 특징을 잡고 분류하기 위해 점점 트리의 깊이가 깊어지다가 데이터의 노이즈나 중요하지 않는 특징도 함께 학습에 활용하게 되는 과적합 문제가 발생한다.

하지만 랜덤 포레스트는 전체 데이터셋에서 일부 데이터와 변수만 무작위로 선정하여 하나가 아닌 여러 개의 의사결정트리를 만들고, 각 트리가 예측한 결과를 종합하여 다수결로 투표하는 방식으로 최종 결과를 결정하는 방식의 알고리즘이다.

이를 앙상블의 배깅 기법이라고 한다. 따라서 단독 의사결정트리와 달리 하나의 트리가 잘못 판단 하더라도 다수결을 통해 결정하기 때문에 데이터 분류 오차를 획기적으로 줄일 수 있을 것이다.

2) 하이퍼파라미터 튜닝

랜덤 포레스트 모델의 효율성을 최적화하기 위해서는 사전에 지정하는 하이퍼파라미터 튜닝이 필요하다. 랜덤 포레스트의 핵심 하이퍼파라미터로는 생성할 트리(의사결정나무)의 총개수를 지정하는 `n_estimators`와, 모델 실행마다 나타나는 무작위성을 억제하기 위한 `random_state`를 통해 산출된 결과를 고정한다.

이 때, 트리의 개수가 너무 적으면 앙상블의 효과가 떨어져 과소적합이 발생할 수 있고 너무 많으면 성능 향상 대비 연산 비용과 메모리 소모가 많아지기 때문에 적당한 트리 개수를 구하는 것이 이번 실험의 관건이다.

3) 혼동 행렬 (Confusion Matrix)

K-NN 알고리즘 시험의 결과와 비교하기 위해 랜덤 포레스트 결과 값을 동일하게 혼동 행렬로 표현함으로써 K-NN과 랜덤 포레스트의 오차 비교를 통해 얼마나 성능이 향상되었는지 파악할 수 있다.

4.3.2 모델 설계 및 실험 방법

1. 랜덤 포레스트 용 하이퍼파라미터 설정, 초기에 생성할 트리의 개수는 50으로 설정하고 난수 발생 초기값을 고정하여 무작위성 억제
2. k-nn실험에서도 사용한 `X_train`(표준화된 센서 학습 데이터)와 `y_train`(활동 라벨 학습 데이터)를 랜덤 포레스트 모델에 학습

3. 학습된 모델의 성능을 확인하기 위해 **X_test**(활동 라벨 평가 데이터)를 통해 결과 예측
4. **y_pred**(모델이 예측한 사용자의 활동 라벨)와 **y_test**(실제 사용자의 활동 라벨) 비교를 위해 결과 분석 표와 혼동 행렬로 시각화
5. **n_estimators**(트리의 개수) 값을 50부터 50씩 증가시키며 랜덤 포레스트 객체를 생성하며 **y_pred**와 **y_test** 간의 오차가 더이상 유의미하게 줄어들지 않는 지점을 파악

4.3.3 랜덤 포레스트 알고리즘 수행 결과 및 분석

4.3.3.1 최종 트리 개수 하이퍼파라미터 산출

트리 개수 차이에 따른 랜덤 포레스트 모델이 예측한 앉기와 서기 라벨의 오차 비교

534	28	536	26	534	28
30	517	23	524	22	525
<u>트리 개수 = 50</u>		<u>트리 개수 = 100</u>		<u>트리 개수 = 150</u>	

<그림 10>

직접 실행을 반복하면서 하이퍼파라미터인 트리 개수(**n_estimators**)를 튜닝한 결과, 트리의 개수가 50개일 때에서 100개로 접어들면서 앉기 라벨과 서기 라벨 간의 오차가 55건에서 49건으로 줄어들었지만 100개일 때에서 150개로 접어들 때는 49건에서 50건으로 오히려 오차가 늘어났다. 이는 트리의 개수가 100개를 기준으로 더 이상 유의미하게 변하지 않는 안정적인 고점에 도달함을 확인할 수 있고 이에 따라 연산 효율성과 예측 안정성을 모두 충족하는 랜덤 포레스트 모델의 최적 트리 개수를 100개로 선정하였다.

4.3.3.2 주요 분석 결과와 K-NN알고리즘과의 비교

```

***   === 🌲 Random Forest 최종 분류 결과 (Classification Report) ===
              precision    recall  f1-score   support


   Walking           0.99      0.99      0.99         539
 Walking Upstairs    0.97      0.99      0.98         424
 Walking Downstairs  0.98      0.97      0.98         420
      Sitting       0.96      0.95      0.95         563
      Standing      0.95      0.96      0.95         547
        Laying      1.00      1.00      1.00         597

   accuracy                   0.98         3090
  macro avg                   0.98         3090
 weighted avg                 0.98         3090
  
```

<그림 11>

최적의 하이퍼파라미터($n_estimators=100$)를 적용하여 최종 랜덤 포레스트 모델을 구축하고 평가 데이터셋(30%)으로 성능을 검증한 결과, 전체 분류 정확도 98%라는 최종 성과를 달성하였다.

이는 단순 거리 기반의 K-NN 알고리즘이 기록한 96%의 정확도보다 약 2% 향상된 수치이다. 정답 라벨 없이 대략적인 영역만 묶었던 비지도 학습(K-Means)과 앉기와 서기 데이터에 혼동을 보였던 단일 지도 학습(K-NN)보다 랜덤포레스트 모델이 스마트폰 센서 데이터 분류에 가장 탁월한 성능을 발휘함을 입증하였다.



<그림 12>

앉기, 서기 라벨 데이터 간 오차를 중점으로 보면, k-nn알고리즘 실험에서는 실제 앉기 라벨을 서기 라벨로 잘못 예측한 건수가 63건, 반대의 경우에는 37건으로 총 100건이었지만, 랜덤 포레스트 모델 적용 후에는 각각 22건, 28건으로 총 50건까지 오차가 줄어든 것을 볼 수 있다.

이를 통해 K-NN에서 이루지 못했던 정적 활동(앉기 vs 서기)의 예측 실패율 대폭 감소에 성공했다는 것을 알 수 있다.

5. 종합 결과 (Comprehensive results)

5.1 프로젝트 요약

본 프로젝트에서는 스마트폰의 가속도계 및 자이로스코프 센서로부터 추출된 특징 데이터를 활용, 사용자의 6가지 일상 행동을 정밀하게 분류하는 모델 구현 및 비교 분석 연구를 진행하였다. 실험은 데이터 전처리 및 표준화를 거친 후, 비지도 학습(K-Means) 단계에서 시작하여, 점진적으로 분류 성능을 고도화하기 위해 지도 학습 알고리즘인 K-NN과 랜덤 포레스트 앙상블 모델을 도입하고 각각의 하이퍼파라미터를 최적화하는 방식으로 전개되었다.

5.2 주요 분석 결과 요약

프로젝트 수행 과정은 알고리즘 모델 적용하고 결과를 분석한 후 한계점을 발견하고 다음 알고리즘에서 극복하는 방식으로 계단식 형태를 띄고 있다.

알고리즘	K-means	K-NN	Random Forest
<u>개선사항</u>	1. 동적과 정적 데이터의 정확한 분류	1. 6가지 행동 라벨의 96% 정확도의 분류 2. 걷기 계열 라벨 완벽 구분	1. 6가지 행동 라벨의 98% 정확도의 분류 2. 앉기, 서기 라벨 간 오차 대폭 하강
<u>한계점</u>	1. 앉기와 서기 라벨 구분 불가능 2. 걷기 계열 라벨 구분 모호	1. 앉기, 서기 라벨의 실제 데이터 간 오차 총 100건이 발생하는 오분류	1. 아직 남아있는 오차 총 50건의 오분류


5.3 가장 성능이 우수한 모델

성능의 기준을 얼마나 6가지 행동을 오차없이 구분했는지 여부로 둔다면, 3가지의 모델 중 가장 성능이 뛰어난 모델은 단연 **Random Forest** 모델이다. **K-means** 모델이 이루어내지 못했던 6가지 행동 라벨을 정확히 구분해내었고, **K-NN** 모델과 비교해도 정확도 96% 대비 2% 상승한 정확도를 보여주었기 때문이다.

5.4 최종 결과 분석

Random Forest 모델이 최고의 알고리즘 모델이 될 수 있었던 이유는 두 가지 이유로 설명 가능하다. 첫 번째 이유로 **K-NN** 모델은 가장 가까운 데이터의 다수결(7개)을 보고 판단하는 모델이다. 하지만 앞서 수행한 비지도 학습(**K-Means**)의 군집화 시각화 결과 그래프를 보면, 센서 수치의 기하학적 거리만으로 데이터를 묶었을 때 이미 앉기와 서기 데이터가 하나의 군집 내에 뭉뚱하게 혼재된 결과를 알 수 있다. 동일하게 데이터 간의 거리만을 측정하는 **K-NN**의 연산 방식은 데이터가 겹쳐있는 영역에서 다수결 오류를 범하기 쉽다.

두 번째 이유는 스마트폰 센서 데이터 특성상 사용자의 일시적인 떨림, 걸음걸이의 불규칙성, 주머니 내부 마찰 등으로 인한 노이즈가 많이 발생한다. 이 때 랜덤 포레스트는 추출된 서로 다른 데이터로 100개의 독립적인 트리를 학습시킨 뒤, 결과를 다수결로 종합하여 결과를 산출한다. 일부 트리가 노이즈 때문에 잘못된 예측을 하더라도, 나머지 대다수의 트리가 올바른 예측을 하면서 최종 평가 데이터셋에 대해 흔들림 없는 강력한 성능을 보여주게 된다.



겹쳐있는 앉기와 서기 라벨(K-means)

<그림 13>

5.5 한계점과 개선 방향

랜덤포레스트 모델을 통해 최종적으로 6개 활동 라벨을 분류했음에도 불구하고, 앉기와 서기 라벨 간

오차는 약 50건이 남아있다. 이는 최종 결과 분석의 첫 번째 이유의 연장선으로 볼 수 있다. 서기와 앉기 라벨 데이터는 서로 겹쳐있을 뿐 아니라 일부 변수가 차이 없이 똑같은 부분이 존재한다.

예를 들면 스쿼트하는 자세와 의자에 앉아있는 행동은 서기와 앉기로 구분되지만 주머니에 있는

센서가 측정한 스마트폰의 각도는 동일하다. 물리적 사각지대로 인해, 정교한 머신러닝 알고리즘을 적용하더라도 순간적인 수치 단면만으로는 완벽한 분류에 한계가 있음을 시사한다.

이러한 구조적인 문제를 해결하기 위한 가장 근본적인 방안은 스마트폰 부착 위치를 다른 위치로 확장하는 것이다. 데이터 셋에 스마트폰이 '바지 주머니'라는 단일 위치를 벗어나 다른 부위에도 스마트폰을 부착한 데이터를 추가한다면 물리적 데이터의 중첩을 원천적으로 차단할 수 있을 것이다.

6. 참고문헌 (References)

[1] 공식 데이터셋 및 연구 논문

UCI Machine Learning Repository. (2012).

Human Activity Recognition Using Smartphones DataSet. Archive

URL:

<https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>.

[2] 기술 문서 및 개발 환경

K-Means 알고리즘 참고.

Scikit-Learn Development Team. (2026). *sklearn.cluster.KMeans API Documentation*.

URL:

<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>

K-NN 알고리즘 참고.

Scikit-Learn Development Team. (2026). *sklearn.neighbors.KNeighborsClassifier API Documentation*.

URL:

<https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>!

Random Forest 참고.

Scikit-Learn Development Team. (2026). *sklearn.ensemble.RandomForestClassifier API Documentation*.

URL:

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

[추가] 팀원별 기여도 및 역할 분담 내역

학번	이름	담당 역할	기여도(%)
----	----	-------	--------

2271036	윤준영	프로젝트 개요 기술, 데이터 수집·전처리 및 PCA 차원 축소, K-Means 군집화 모델링 및 분석	33.3%
2191096	김용우	K-NN 분류 모델링 및 하이퍼파라미터(K) 튜닝 분석	33.3%
2271252	유민혁	Random Forest 앙상블 모델링, 모델별 성능 비교 분석, 핵심 인사이트 및 한계점 도출	33.3%

공동 진행 영역

- 주 1회 정기 팀 미팅을 통한 프로젝트 진행 상황 및 개발 소스코드 공유 (노션 워크스페이스 활용)
- 프로젝트 주제 선정 및 수집 데이터셋 확정
- 각 머신러닝 알고리즘 적용 결과에 대한 토론 및 피드백 수행
- 최종 결과 보고서 작성 및 검토